

許登翔
313513066

陽明交通大學 114 年度上學期 機器學習 Homework #3

劉益宏 教授 2025/11/03

1. 目的：利用鳶尾花資料(Iris data set)來訓練 Support Vector Machine (SVM)，採用 one-against-one strategy 來處理三類別分類問題，並以 grid search 來最佳化 SVM 之參數 C 與 σ ，其過程再以 two-fold cross validation 使所得到的最佳參數組具有較佳的泛化性。
2. 作業內容：
 - Step1. 將Iris data set的山鳶尾(Setosa)、變色鳶尾(Versicolor)以及維吉尼亞鳶尾(Virginica)各別取前25筆data設為training data, 剩餘的75筆設為test data, 所有資料皆採用全部4個特徵，並採用同一組SVM參數(C 與 σ)進行以下訓練及測試流程。
 - Step2. 將山鳶尾(Setosa)以及變色鳶尾(Versicolor)分別設為positive class與negative class，並以這兩類training data訓練SVM₁₂。
 - Step3. 將山鳶尾(Setosa) 以及維吉尼亞鳶尾(Virginica)分別設為positive class與negative class，並以這兩類training data訓練SVM₁₃。
 - Step4. 將變色鳶尾(Versicolor)以及維吉尼亞鳶尾(Virginica)分別設為positive class與negative class，並以這兩類training data訓練SVM₂₃。
 - Step5. 將test data分別輸入至Step2 – Step4所訓練的3組SVM decision function，並根據3組SVM的決策結果採多數決進行分類，若同票則該筆資料視為分類錯誤，並於最後得到第一個測試分類率。
 - Step6. 將Step1的training data與test data互換，並重複Step1 – Step5進行交叉驗證得到第二個測試分類率。
 - Step7. 將Step5與Step6求出的兩個分類率平均，得到平均分類率 (數值請列到小數點後第2位，in %)，並記錄下來。
 - Step8. 改用下一組SVM參數(C 與 σ)來重複Step1 – Step7，直到所有參數組合(7×41組)皆完成測試，並將每組參數的分類率記錄下來，並標註最佳化後的參數組及分類率。

其中，本次作業皆採用RBF-kernel之SVM，且grid search範圍如下：

C : 1, 5, 10, 50, 100, 500, 1000

σ : $1.05^{-100}, 1.05^{-95}, \dots, 1.05^{-10}, 1.05^{-5}, 1.05^0, 1.05^5, 1.05^{10}, \dots, 1.05^{95}, 1.05^{100}$

1. Grid search

sigma\C	1	5	10	50	100	500	1000
0.0076	54.00%	54.00%	54.00%	54.00%	54.00%	54.00%	54.00%
0.0097	66.67%	66.67%	66.67%	66.67%	66.67%	66.67%	66.67%
0.0124	49.33%	49.33%	49.33%	49.33%	49.33%	49.33%	49.33%
0.0158	51.33%	51.33%	51.33%	51.33%	51.33%	51.33%	51.33%
0.0202	51.33%	51.33%	51.33%	51.33%	51.33%	51.33%	51.33%
0.0258	51.33%	51.33%	51.33%	51.33%	51.33%	51.33%	51.33%
0.0329	41.33%	41.33%	41.33%	41.33%	41.33%	41.33%	41.33%
0.0419	45.33%	49.33%	49.33%	49.33%	49.33%	49.33%	49.33%
0.0535	54.00%	56.00%	56.00%	56.00%	56.00%	56.00%	56.00%
0.0683	63.33%	63.33%	63.33%	63.33%	63.33%	63.33%	63.33%
0.0872	65.33%	66.00%	66.00%	66.00%	66.00%	66.00%	66.00%
0.1113	74.00%	74.67%	74.67%	74.67%	74.67%	74.67%	74.67%
0.1420	84.67%	85.33%	85.33%	85.33%	85.33%	85.33%	85.33%
0.1813	90.67%	90.00%	90.00%	90.00%	90.00%	90.00%	90.00%
0.2314	94.00%	92.67%	92.67%	92.67%	92.67%	92.67%	92.67%
0.2953	95.33%	95.33%	95.33%	95.33%	95.33%	95.33%	95.33%
0.3769	95.33%	94.67%	95.33%	95.33%	95.33%	95.33%	95.33%
0.4810	95.33%	95.33%	95.33%	96.67%	96.67%	96.67%	96.67%
0.6139	94.67%	95.33%	95.33%	96.00%	96.67%	96.67%	96.67%
0.7835	96.00%	95.33%	95.33%	94.67%	94.67%	95.33%	95.33%
1.0000	95.33%	95.33%	94.67%	95.33%	95.33%	96.00%	96.00%
1.2763	96.00%	95.33%	96.67%	96.00%	96.67%	95.33%	96.00%
1.6289	95.33%	96.00%	96.00%	94.67%	96.00%	95.33%	94.67%
2.0789	95.33%	96.00%	95.33%	94.00%	95.33%	95.33%	94.67%
2.6533	95.33%	96.00%	96.00%	97.33%	94.67%	95.33%	95.33%
3.3864	94.67%	95.33%	96.00%	98.00%	97.33%	95.33%	95.33%
4.3219	94.67%	96.67%	95.33%	96.00%	98.00%	96.00%	94.67%
5.5160	93.33%	95.33%	98.00%	96.67%	98.67%	96.67%	96.00%
7.0400	75.33%	95.33%	96.00%	96.67%	96.67%	98.00%	96.00%
8.9850	74.67%	94.67%	95.33%	96.00%	96.67%	98.67%	97.33%
11.4674	66.67%	93.33%	94.67%	95.33%	97.33%	98.67%	98.00%
14.6356	33.33%	90.67%	93.33%	96.67%	96.00%	96.67%	98.67%
18.6792	33.33%	90.67%	92.67%	95.33%	97.33%	96.67%	98.67%
23.8399	33.33%	50.00%	66.67%	94.67%	94.00%	97.33%	96.67%
30.4264	33.33%	50.00%	92.67%	93.33%	94.67%	95.33%	96.67%
38.8327	33.33%	33.33%	50.00%	92.67%	95.33%	98.67%	96.67%
49.5614	33.33%	33.33%	33.33%	92.00%	93.33%	96.67%	95.33%
63.2544	33.33%	33.33%	33.33%	94.00%	90.67%	95.33%	97.33%
80.7304	33.33%	33.33%	33.33%	66.67%	92.00%	94.67%	95.33%
103.0347	33.33%	33.33%	33.33%	33.33%	90.00%	94.67%	95.33%

2. Optimal classification rate & parameters of each combination and classification rate without using 2-fold validation for averaging

```
Best CR   : 98.67%  
fold-1 CR : 98.67%  
fold-2 CR : 98.67%  
Best comb : C = 100, sigma = 5.5160153675922565
```

```
Best CR   : 98.67%  
fold-1 CR : 98.67%  
fold-2 CR : 98.67%  
Best comb : C = 500, sigma = 8.985007793492823
```

```
Best CR   : 98.67%  
fold-1 CR : 98.67%  
fold-2 CR : 98.67%  
Best comb : C = 500, sigma = 11.4673997857537
```

```
Best CR   : 98.67%  
fold-1 CR : 98.67%  
fold-2 CR : 98.67%  
Best comb : C = 500, sigma = 38.83268592375563
```

```
Best CR   : 98.67%  
fold-1 CR : 98.67%  
fold-2 CR : 98.67%  
Best comb : C = 1000, sigma = 14.6356309163739
```

```
Best CR   : 98.67%  
fold-1 CR : 98.67%  
fold-2 CR : 98.67%  
Best comb : C = 1000, sigma = 18.679185894122995
```

1. 參數 C 是控制模型對於分類錯誤的容忍度，也就是懲罰錯誤分類的成本

(i) 當 C 較大時：錯誤分類 cost 很大，因此模型傾向於減少分類錯誤

⇒ margin 變窄，也較為容易產生 Overfitting，特別是在訓練資料中包含雜訊時

(ii) 當 C 較小：允許部分的分類錯誤，使模型更具彈性 (margin 變大)，能避免 Overfitting

因此在模型上須選擇適當大小的 C 值，有助於提升分類率和泛化能力

* 在本次數據集中，可以看到分類率最大為 98.67%，集中於 $C=600, 500, 600$

若是將 C 繼續增加，便可能導致後續因 Overfitting 使分類率下降

2.

在 RBF kernel 中 $k(x,y) = \exp(-\frac{\|x-y\|^2}{2\sigma^2})$ ， σ^2 控制 kernel 的擴散程度

(i) σ^2 大：使 kernel function 非常寬，導致較多數據點的影響疊加，使 decision boundary 更為平滑、線性，適合數據較為分散的情況

(ii) σ^2 小：使 kernel function 較窄，一方面使數據點集中於有限點，提升區別能力，但也可能因此使 decision boundary 很彎曲產生 Overfitting。

3. 若不使用 two fold cross validation，而是使用其它分配方式處理，可能可以得到更好的 CR，但若使用較大 k ，則能更全面平衡數據集中 train 和 test 間的偏差

* 捨棄交叉驗證或 $k=1$ 時，可能導致 CR 在測試集中提升，但可能僅是特定集中的擬合結果，而非真正的泛化能力